


Figure A 희귀 한국어 표현의 토큰 분절 — 정규화 여부로 결론이 뒤집힌다
concept 24쌍 paired 비교. y축 라벨은 concept_id 와 rare 표현 (진한 라벨 = unsafe concept). 두 패널의 concept 순서는 동일하다.

SGuard (byte-level BPE)
AltDiffusion (SentencePiece)

A 원시 key 토큰 수
rare - common (음수 = 희귀 표현이 토큰을 적게 씀)



B 문자당 토큰 수로 정규화
rare - common (양수 = 희귀 표현이 더 잘게 분절)

